


UNIVERSIDAD NACIONAL FEDERICO VILLARREAL
FACULTAD DE INGENIERÍA ELECTRÓNICA E INFORMÁTICA
ESCUELA PROFESIONAL DE INGENIERÍA INFORMÁTICA
INTELIGENCIA ARTIFICIAL



SISTEMA DE PREDICCIÓN DE RIESGO DE ANEMIA INFANTIL
Y SEGMENTACIÓN DE CASOS EN SAN MARTÍN, PERÚ

DOCENTE:
CIRO RODRIGUEZ RODRIGUEZ

ALUMNA:
PACHECO ANTÓN FÁTIMA DE LOS ÁNGELES

CÓGIGO:
2024020561

LIMA, PERÚ
2026

ÍNDICE

ÍNDICE	2
1. RESUMEN	3
2. PALABRAS CLAVES	3
3. INTRODUCCIÓN	3
4. SITUACIÓN PROBLEMÁTICA	4
5. IDENTIFICACIÓN Y FORMULACIÓN DEL PROBLEMA	5
6. PREGUNTA DE INVESTIGACIÓN	5
7. OBJETIVO GENERAL	6
7.1. OBJETIVO ESPECÍFICOS	6
8. MATRIZ DE TRAZABILIDAD	6
9. JUSTIFICACIÓN	7
10. ANTECEDENTES Y ESTADO DEL ARTE	8
11. MARCO CONCEPTUAL	10
12. METODOLOGÍA DE INVESTIGACIÓN	11
13. METODOLOGÍA DE DESARROLLO DE IA	12
14. FASE 1 - COMPRENSIÓN DEL PROBLEMA	13
15. FASE 2 - COMPRENSIÓN DE LOS DATOS	13
16. FASE 3 - INGENIERÍA Y PREPARACIÓN DE LOS DATOS	14
17. DISEÑO DE LA SOLUCIÓN	16
17.1. TÉCNICAS DE INGENIERÍA DE SOFTWARE APLICADAS A IA	17
18. DESARROLLO DE LA IMPLEMENTACIÓN	18
18.1. DISEÑO DEL MODELO DE IA	18
18.2. MODELO BASE (BASELINE)	18
19. DISEÑO DE EXPERIMENTACIÓN	18
20. EVALUACIÓN	19
20.1. MÉTRICAS DE EVALUACIÓN	19
20.2. VALIDACIÓN	19
20.3. COMPARACIÓN DE MODELOS	19
20.4. INTERPRETABILIDAD	20
20.5. EVALUACIÓN DEL ARTEFACTO Y PROTOTIPO	20
20.6. DESPLIEGUE Y REPRODUCIBILIDAD	20
21. RESULTADOS	20
21.1. Resultados del Análisis Exploratorio (EDA)	20
21.2. Resultados de la Predicción de Riesgo (Regresión Logística)	22
21.3. Resultados de la Segmentación (K-Means)	23
22. DISCUSIÓN	25
23. AMENAZAS A LA VALIDEZ Y LIMITACIONES	26
24. CONSIDERACIONES ÉTICAS	27
25. REPRODUCIBILIDAD	28
26. CONCLUSIONES	28
27. RECOMENDACIONES	29
27.1. TRABAJO FUTURO	30
28. REFERENCIAS	30
29. ANEXOS	31
30. README	34
31. MATRIZ DE TRAZABILIDAD FINAL	34

Sistema de predicción de riesgo de anemia infantil y segmentación de casos en San Martín, Perú

1. RESUMEN

La anemia infantil por deficiencia de hierro sigue siendo un problema de salud pública persistente en el Perú, con prevalencias históricas que superaban el 40% en niños menores de 36 meses, y que para el cierre de 2025 se situó en un 34.9% a nivel nacional. Este trabajo aborda el problema a partir de un registro real, usando el dataset ANEMIA_DA, publicado en la Plataforma Nacional de Datos Abiertos del Perú por el Ministerio de Salud, correspondiente a 59,225 casos diagnosticados con anemia en la región San Martín entre 2016 y 2025.

Se desarrollaron dos modelos de aprendizaje automático complementarios: una Regresión Logística que predice si un caso corresponde a un riesgo de severidad mayor (moderada o severa) frente a uno leve, a partir de variables demográficas y geográficas; y un modelo K-Means que agrupa a los casos según su perfil de edad y ubicación, sin usar la etiqueta de severidad, permitiendo una validación externa de los grupos encontrados, metodología respaldada por estudios recientes de clasificación hematológica mediante algoritmos supervisados.

La metodología siguió CRISP-DM: comprensión, limpieza de datos y una partición train/validación/test de 60/20/20 con estratificación y escalado ajustado únicamente sobre el conjunto de entrenamiento, para prevenir fuga de información (data leakage). Los resultados muestran que la Regresión Logística logra detectar más de 6 de cada 10 casos de riesgo severo reales en el conjunto de prueba. El modelo K-Means, con $k=4$, identificó grupos geográficos con proporciones de severidad moderada distintas entre sí, lo que sugiere heterogeneidad espacial en el riesgo y demuestra la viabilidad de la IA para optimizar la toma de decisiones preventivas.

2. PALABRAS CLAVES

Anemia infantil, aprendizaje automático, Regresión Logística, K-Means, datos abiertos, salud pública, Perú

3. INTRODUCCIÓN

La anemia, definida por la Organización Mundial de la Salud (OMS) como una concentración de hemoglobina inferior a 11 g/dL para niños de 6 a 59 meses [3], es uno de los problemas nutricionales más extendidos entre los niños peruanos. Distintas ediciones de la Encuesta Demográfica y de Salud Familiar (ENDES) han reportado prevalencias alarmantes, con una concentración marcada en la sierra y la selva del país, entre ellas la región San Martín [4].

Dada la situación, el Ministerio de Salud a través de la Plataforma Nacional de Datos Abiertos hace de conocimiento público estos registros. A diferencia de una encuesta muestral, este tipo de registro recoge la totalidad de los casos atendidos en los establecimientos de salud, lo que ofrece una base masiva indispensable para aplicar técnicas predictivas de aprendizaje automático (Machine Learning), un enfoque que ha demostrado alta eficacia en estudios recientes para clasificar tipos y severidad de anemia utilizando datos sociodemográficos y hematológicos [5].

4. SITUACIÓN PROBLEMÁTICA

La anemia infantil persiste como uno de los principales problemas de salud pública en el Perú, con consecuencias irreversibles en el desarrollo cognitivo, motor y emocional durante los primeros años de vida [6]. De acuerdo con los resultados oficiales de la ENDES del Instituto Nacional de Estadística e Informática (INEI), para el cierre del año 2025, el 34.9% de la población de 6 a 35 meses de edad sufrió de anemia a nivel nacional [1]. Esta condición presenta brechas significativas según el área de residencia, concentrando factores de riesgo críticos que dificultan su erradicación.

El seguimiento actual de los casos por parte de las entidades de salud se apoya principalmente en reportes agregados y en estudios estadísticos clásicos. Aunque el Ministerio de Salud (MINSA) implementa estrategias de suplementación, el enfoque es predominantemente descriptivo. Este modelo tradicional no permite priorizar de manera individualizada qué pacientes diagnosticados tienen mayor probabilidad de evolucionar hacia un grado de anemia severa, ni permite segmentar de forma automatizada los perfiles geográfico-demográficos donde el riesgo tiende a concentrarse de manera crítica.

El análisis preliminar de la situación evidencia una limitación operativa: la incapacidad de predecir la severidad a partir de las variables sociodemográficas disponibles antes de que el cuadro empeore. Frente a esta necesidad, un sistema que combine un modelo de clasificación predictiva (Regresión Logística) con modelos de agrupamiento (K-Means) puede aportar una capa adicional de inteligencia artificial, facilitando la priorización temprana de los recursos sin reemplazar el criterio clínico médico.

5. IDENTIFICACIÓN Y FORMULACIÓN DEL PROBLEMA

Para la identificación estructurada de la situación, se aplicó la técnica de análisis mediante Árbol de Problemas:

Problema general: Limitada capacidad analítica en el enfoque de salud pública tradicional para predecir el riesgo individual de severidad y descubrir patrones ocultos en pacientes pediátricos con anemia.

Causas:

1. Dependencia exclusiva de estadística descriptiva tradicional.
2. Subutilización del gran volumen de datos tabulares históricos recopilados.
3. Carencia de herramientas automatizadas, a pesar de que la literatura científica actual demuestra que algoritmos como la Regresión Logística mejoran significativamente la predicción de enfermedades hematológicas [5].

Consecuencias: Asignación ineficiente de suplementos nutricionales e intervenciones tardías que derivan en daños irreversibles en la capacidad de exploración, memoria y aprendizaje del infante [6].

Evidencias: Índices del INEI que reportan un 34.9% de incidencia en 2025 [1] y la existencia del registro abierto ANEMIA_DA del MINSA.

Necesidad: Se requiere predecir el nivel de riesgo (severidad) de nuevos pacientes y segmentar los perfiles geográfico-demográficos para optimizar decisiones preventivas focalizadas.

6. PREGUNTA DE INVESTIGACIÓN

¿En qué medida la combinación de un modelo de clasificación (Regresión Logística) y un modelo de agrupamiento (K-Means) permite predecir el riesgo de severidad mayor y segmentar perfiles de casos de anemia infantil, a partir del registro abierto ANEMIA_DA del Ministerio de Salud del Perú?

7. OBJETIVO GENERAL

Desarrollar y evaluar un sistema de aprendizaje automático compuesto por un modelo de clasificación y un modelo de agrupamiento complementarios, capaz de predecir el riesgo de severidad mayor y segmentar perfiles de casos de anemia infantil a partir del registro abierto del Ministerio de Salud del Perú.

7.1. OBJETIVO ESPECÍFICOS

OE1: Realizar el análisis exploratorio de datos (EDA) del dataset ANEMIA_DA, identificando la distribución de la variable de severidad y las correlaciones relevantes entre variables numéricas.

OE2: Diseñar el proceso de limpieza y preprocesamiento de datos, incluyendo la estandarización de unidades de edad, el descarte de registros inválidos y la codificación de variables categóricas.

OE3: Diseñar un esquema de partición de datos (entrenamiento, validación y prueba) que prevenga la fuga de información (data leakage) durante el modelado.

OE4: Implementar un modelo de Regresión Logística para la clasificación del riesgo de severidad mayor y un modelo K-Means para la segmentación de perfiles de casos.

OE5: Evaluar empíricamente el modelo de clasificación frente a un baseline de referencia, utilizando Accuracy, Precision, Recall, F1-score y matriz de confusión.

OE6: Evaluar el modelo de agrupamiento mediante el método del codo, el silhouette score, y una validación externa cruzando los clusters obtenidos contra la severidad real.

8. MATRIZ DE TRAZABILIDAD

Esta matriz permite verificar la coherencia metodológica del proyecto, vinculando el problema identificado con las preguntas específicas, los objetivos trazados y la evidencia empírica que se generará como resultado.

Problema identificado	Pregunta específica	Objetivo	Método (Metodología)	Resultado esperado	Evidencia (Indicadores)
Problema Principal: Limitada capacidad predictiva y de segmentación en salud pública tradicional.	Pregunta principal: ¿En qué medida la combinación de Regresión Logística y K-Means permite predecir riesgo y segmentar casos?	OG	CRISP-DM, Machine Learning	Sistema de clasificación y agrupamiento funcional.	Prototipo, Código entrenado.
Causa 1: Subutilización de registros con ruido y datos inconsistentes.	¿Cuáles son las características distribucionales y correlaciones del registro ANEMIA_DA?	OE1, OE2	Análisis Exploratorio (EDA) y Preprocesamiento.	Dataset limpio, estandarizado y codificado.	Heatmap de correlación, Data Card y CSV preparado.
Causa 2: Riesgo estadístico de sobreajuste al evaluar modelos.	¿Cómo estructurar los datos para garantizar una evaluación predictiva imparcial?	OE3	Partición estratificada (60/20/20).	Esquema de validación sin fuga de información.	Dimensiones de matrices Train/Val/Test en código.
Necesidad de predicción y agrupación automatizada:	¿Qué arquitecturas algorítmicas permiten clasificar riesgo y segmentar los casos clínicos?	OE4	Implementación de Regresión Logística y K-Means.	Modelos matemáticos entrenados sobre los datos.	Parámetros del modelo (código fuente).
Necesidad de validación predictiva:	¿Qué desempeño presenta la Regresión Logística comparada con un enfoque ingenuo?	OE5	Experimentación y métricas de clasificación.	Superioridad del modelo predictivo sobre el baseline.	F1-score, Recall y Matriz de confusión.
Necesidad de segmentación:	¿Existen patrones coherentes en los clústeres geográfico-demográficos descubiertos?	OE6	Validación interna y externa de clústeres.	Clústeres definidos acordes a la severidad real.	Gráfico del codo y Silhouette score.

Figura 1: Tabla Markdown a base del Árbol de problemas

9. JUSTIFICACIÓN

El presente proyecto se justifica desde cuatro perspectivas fundamentales para la ingeniería y la investigación aplicada:

Justificación práctica

El sistema propuesto ayuda a resolver la asignación ineficiente y reactiva de los recursos de salud pública frente a la anemia infantil. Al predecir qué pacientes tienen mayor probabilidad de evolucionar hacia cuadros severos, permite a las entidades de salud priorizar intervenciones tempranas y focalizadas, optimizando la distribución de suplementos nutricionales y el seguimiento clínico en las zonas de mayor riesgo.

Justificación tecnológica

El enfoque tradicional de reportes agregados explica el pasado de la enfermedad, pero es insuficiente para proyectar riesgos futuros a nivel individual. Se justifica el uso de Inteligencia Artificial porque los modelos de aprendizaje automático tienen la capacidad matemática de procesar miles de registros simultáneamente y detectar relaciones complejas entre variables demográficas y clínicas, automatizando una tarea analítica.

Justificación científica

El uso de datos abiertos para el modelado predictivo en salud pública permite aprovechar bases de información ya recolectadas por el Estado, sentando un precedente de investigación transparente y reproducible, donde cualquier interesado puede descargar el mismo dataset y auditar los resultados. Adicionalmente, el despliegue empírico de un modelo supervisado (Regresión Logística) junto con uno no supervisado (K-Means) sobre el mismo problema aporta evidencia bidimensional: predicción individual de riesgo y segmentación espacial de grupos.

Justificación metodológica

Para construir y evaluar la solución se emplea la metodología CRISP-DM (Cross-Industry Standard Process for Data Mining), la cual proporciona un estándar riguroso de ingeniería de datos [1]. Este marco metodológico garantiza que el desarrollo no sea empírico, sino que siga un proceso auditable desde la limpieza estructurada del registro ANEMIA_DA, hasta el diseño de particiones estrictas de datos y la evaluación de los algoritmos mediante métricas formales.

10. ANTECEDENTES Y ESTADO DEL ARTE

La revisión de la literatura evidencia un interés reciente en la aplicación de algoritmos de aprendizaje automático para el diagnóstico y análisis epidemiológico. A continuación, se detallan dos investigaciones clave que fundamentan metodológica y algorítmicamente este proyecto:

Antecedente 1: Predicción de severidad mediante algoritmos supervisados

Basado en el estudio de Sabatini et al. [2] sobre sistemas de clasificación hematológica:

1. **¿Qué problema estudió?** La clasificación automatizada de tipos y niveles de severidad de anemia en pacientes pediátricos para agilizar el triaje médico.
2. **¿Qué datos utilizó?** Registros médicos electrónicos (EHR) y datos demográficos de bases hospitalarias controladas.
3. **¿Qué metodología empleó?** Utilizó el ciclo de vida CRISP-DM, aplicando particiones estratificadas y validación cruzada (Cross-validation).
4. **¿Qué algoritmo utilizó?** Evaluó Regresión Logística, Support Vector Machines (SVM) y Random Forest.
5. **¿Qué métricas reportó?** Accuracy, Precision, Recall y F1-Score.
6. **¿Qué resultados obtuvo?** La Regresión Logística demostró el mejor equilibrio entre interpretabilidad clínica y costo computacional, logrando un F1-Score general de 0.82 para la detección de riesgo.
7. **¿Qué limitación presenta?** El estudio se realizó en un entorno clínico europeo estrictamente controlado, sin considerar variaciones demográficas abiertas o sesgos geográficos propios de regiones en vías de desarrollo.
8. **¿Cómo se relaciona con el proyecto?** Este antecedente respalda directamente la viabilidad matemática de utilizar Regresión Logística como modelo principal para clasificar la severidad de la anemia (leve frente a moderada/severa) a partir de datos tabulares, sirviendo como fundamento para el Objetivo Específico 4.

Antecedente 2: Descubrimiento de perfiles mediante algoritmos no supervisados

Basado en las investigaciones sobre minería de datos aplicada a la salud pública poblacional desarrolladas por Tian et al. [5]:

1. **¿Qué problema estudió?** La segmentación de pacientes con deficiencias nutricionales para identificar perfiles de riesgo ocultos a nivel geográfico y etario.
2. **¿Qué datos utilizó?** Bases de datos abiertas proporcionadas por instituciones gubernamentales de salud.
3. **¿Qué metodología empleó?** Proceso iterativo de Knowledge Discovery in Databases (KDD) con fuerte énfasis en el preprocesamiento de valores nulos espaciales.
4. **¿Qué algoritmo utilizó?** K-Means y Clustering Jerárquico.
5. **¿Qué métricas reportó?** Método del Codo (Elbow Method) para determinar k y el coeficiente de Silhouette.
6. **¿Qué resultados obtuvo?** K-Means logró segmentar a la población en clústeres distintos con un Silhouette Score promedio de 0.51, revelando patrones de concentración de riesgo no lineales.
7. **¿Qué limitación presenta?** Los clústeres obtenidos fueron analizados puramente desde la perspectiva matemática, careciendo de una variable de diagnóstico clínico fuerte que permitiera validar si los grupos tenían un sentido médico real.
8. **¿Cómo se relaciona con el proyecto?** Justifica el uso de K-Means para la segmentación geográfica y etaria de la región San Martín. Además, nuestro proyecto supera la limitación de este antecedente, ya que nosotros utilizaremos la etiqueta real de "severidad" del dataset para realizar una validación externa cruzada de los clústeres descubiertos.

11. MARCO CONCEPTUAL

Para el desarrollo del presente proyecto, se definen los siguientes conceptos fundamentales, sustentados en la literatura científica especializada en ciencias de la computación:

- ❖ **Machine Learning (Aprendizaje Automático):** Subcampo de la Inteligencia Artificial que se enfoca en el desarrollo de algoritmos capaces de identificar patrones complejos y mejorar su desempeño en una tarea específica a partir de la exposición a datos empíricos, sin requerir reglas de programación explícitas [7].
- ❖ **Aprendizaje Supervisado y Clasificación:** Paradigma del Machine Learning donde el algoritmo aprende de un conjunto de datos que ya contiene las respuestas correctas (etiquetas). La clasificación es la tarea

supervisada que consiste en predecir una categoría discreta (como el nivel de "riesgo de severidad") para nuevas observaciones [8].

- ❖ **Aprendizaje No Supervisado y Clustering (Agrupamiento):** Enfoque donde los datos de entrenamiento no poseen etiquetas previas. El clustering busca descubrir estructuras ocultas naturales en los datos, agrupando registros (pacientes) de tal forma que los elementos de un mismo clúster sean más similares entre sí que con los de otros grupos [8].
- ❖ **Variable Objetivo (Target) y Características (Features):** Las características son los atributos individuales y medibles del fenómeno observado (ej. edad, latitud, longitud). La variable objetivo es el atributo específico que el modelo supervisado intenta predecir a partir de dichas características [7].
- ❖ **Partición de Datos (Entrenamiento, Validación y Testing):** Práctica estándar para evaluar algoritmos. El conjunto de entrenamiento se usa para que el modelo aprenda los parámetros; el de validación para ajustar la configuración del modelo y evitar sesgos; y el de testing (prueba) se aísla completamente para medir el rendimiento final en un escenario real simulado [9].
- ❖ **Generalización, Overfitting y Underfitting:** La generalización es la capacidad del modelo entrenado para realizar predicciones precisas sobre datos nuevos y nunca antes vistos. El overfitting (sobreajuste) ocurre cuando el modelo memoriza el ruido de los datos de entrenamiento y falla en la generalización. Por el contrario, el underfitting (subajuste) sucede cuando el algoritmo es demasiado simple para capturar la estructura subyacente del problema [9].

12. METODOLOGÍA DE INVESTIGACIÓN

Para el desarrollo del presente proyecto, se establecen los siguientes lineamientos metodológicos:

- **Enfoque de investigación:** Cuantitativo. El estudio se fundamenta en la recolección, procesamiento y análisis matemático de un volumen masivo de datos estructurados (59,225 registros del dataset ANEMIA_DA). Asimismo, la validación de las hipótesis y el rendimiento de los modelos se mide estrictamente mediante métricas estadísticas y numéricas (F1-score, Recall, coeficiente de Silhouette).

- **Tipo de investigación:** Aplicada y tecnológica. El proyecto no busca descubrir nuevas teorías matemáticas, sino utilizar el estado del arte actual del aprendizaje automático para resolver un problema práctico y concreto de la sociedad peruana: optimizar la identificación del riesgo de anemia infantil severa.
- **Diseño de investigación:** Design Science Research (DSR). Dado que el objetivo principal es la construcción de un artefacto tecnológico (un sistema algorítmico predictivo y de segmentación), se justifica el uso de DSR. El proceso seguirá la secuencia lógica de este diseño empírico:
 1. Identificación del problema (limitaciones del enfoque de salud tradicional).
 2. Definición de objetivos (desarrollo de modelos complementarios).
 3. Diseño y desarrollo (ingeniería de datos e implementación de Regresión Logística y K-Means).
 4. Demostración (entrenamiento del modelo con datos de la región San Martín).
 5. Evaluación (medición de las métricas frente a un modelo baseline).
 6. Comunicación (el presente informe de investigación).

13. METODOLOGÍA DE DESARROLLO DE IA

El desarrollo algorítmico del sistema se rigió por la integración de la metodología estándar CRISP-DM (Cross-Industry Standard Process for Data Mining) acoplada con los lineamientos empíricos de Design Science Research y prácticas fundamentales de Ingeniería de Software. Esta estructura formal asegura una transición técnica ordenada desde la necesidad clínica hasta el artefacto computacional [1].

El trabajo se organizó bajo las seis fases iterativas de CRISP-DM:

1. **Business Understanding (Comprensión del negocio):** Análisis del contexto de salud pública y las políticas del MINSA.
2. **Data Understanding (Comprensión de los datos):** Exploración estructural y estadística del archivo gubernamental.
3. **Data Preparation (Preparación de los datos):** Limpieza, imputación y estratificación estructurada para prevenir fugas de información.

4. **Modeling (Modelado):** Diseño algorítmico de la Regresión Logística y la segmentación espacial mediante K-Means.
5. **Evaluation (Evaluación):** Contraste riguroso de resultados matemáticos frente a modelos base (baselines).
6. **Deployment (Despliegue):** Puesta en marcha de la solución tecnológica.

Adicionalmente, superando el estándar clásico que muchas veces omite la documentación técnica post-desarrollo, el proyecto adoptó el ciclo de vida extendido de ingeniería propuesto para la construcción de sistemas de IA [1]:

Problema → Requisitos → Datos → Diseño → Implementación → Evaluación → Despliegue → Mantenimiento.

En el contexto de este estudio, la fase de despliegue se delimitó al entorno académico. En lugar de una implementación productiva en servidores hospitalarios, el sistema se empaquetó como un artefacto de código documentado, trazable y totalmente reproducible en un repositorio estructurado, dejando sentadas las bases técnicas para su futuro mantenimiento o integración como API médica.

14. FASE 1 - COMPRENSIÓN DEL PROBLEMA

La formulación del proyecto inició con el análisis del contexto de salud pública en la región San Martín, identificando a los principales stakeholders: el Ministerio de Salud (MINSA) como entidad gestora de la información, el personal médico de los centros de salud (usuarios de la inteligencia artificial), y los pacientes pediátricos (beneficiarios finales).

El proceso actual de asignación de recursos y seguimiento clínico se basa en cuadros descriptivos que no proyectan el riesgo futuro de los casos ya diagnosticados. En consecuencia, el problema operativo radica en la incapacidad de clasificar de forma temprana a los pacientes vulnerables hacia un riesgo de severidad mayor. Como criterio de éxito para la solución basada en IA, se estableció que el modelo de clasificación supervisada debe superar estrictamente las métricas predictivas (Accuracy y F1-score) de un modelo ingenuo o baseline.

15. FASE 2 - COMPRENSIÓN DE LOS DATOS

Los datos provienen del repositorio gubernamental oficial del Estado Peruano. Para la construcción de la solución, se descargó el registro tabular estructurado, cuyas propiedades iniciales fueron auditadas directamente mediante librerías de manipulación de datos en Python.

Ficha de Caracterización de Datos

- **Fuente:** Plataforma Nacional de Datos Abiertos (MINSA).
- **Periodo temporal:** 1 de enero de 2016 al 26 de abril de 2025 [4].
- **Número de registros crudos:** 59,225 filas [4].
- **Variables originales:** 22 características (tipos flotantes, enteros y objetos) [4].
- **Unidad de análisis:** Paciente pediátrico diagnosticado con anemia en establecimientos de salud de la región San Martín.
- **Variable objetivo (Target):** RIESGO_SEVERO, derivada algorítmicamente de la columna GRADO_SEVERIDAD para resolver un problema de clasificación binaria (Leve = 0; Moderada/Severa = 1).
- **Formato y procedencia:** Archivo CSV (codificación UTF-8-SIG), adquirido mediante acceso de datos abiertos sin restricciones de licenciamiento para investigación académica.

16. FASE 3 - INGENIERÍA Y PREPARACIÓN DE LOS DATOS

16.1. Calidad de los datos

El escrutinio computacional del dataset demostró una alta completitud sin valores nulos absolutos detectados por la función `.isna()`. Sin embargo, se evidenciaron problemas críticos de consistencia, tales como errores tipográficos en la columna de severidad ("LEV" frente a "lev") e inconsistencias en la captura de las edades (unidades fragmentadas en años, meses y días, e ingresos de edades negativas imposibles biológicamente) [4].

16.2. Exploratory Data Analysis - EDA

Se procedió a la exploración visual estadística para comprender la geometría de la información antes del modelado:

- + **Distribución de clases:** La población presentó un fuerte desbalance de clases, concentrando un 78.4% de los diagnósticos en la categoría leve, y solo un 21.6% en el espectro de riesgo severo (moderada y severa), justificando la posterior configuración algorítmica de pesos balanceados (`class_weight="balanced"`) en el clasificador [4].
- + **Correlaciones:** El análisis mediante matriz térmica (heatmap) permitió descartar la multicolinealidad extrema y visualizar las interacciones iniciales entre la edad transformada, coordenadas geográficas y el riesgo.

16.3. Preparación e ingeniería de datos (Feature Engineering)

Las transformaciones aplicadas al conjunto crudo se fundamentaron en técnicas de ingeniería, abarcando:

- Limpieza: Supresión de duplicados exactos y estandarización del texto a mayúsculas para las categorías objetivo.
- Transformación: Función matricial para unificar todas las edades a una sola unidad temporal (meses). Posteriormente, se descartaron los registros fuera del rango de interés pediátrico (mayores a 180 meses) y aquellos con valores negativos (4 filas descartadas) [4].
- Selección y Codificación: Se eliminaron las columnas sin varianza (ej. DEPARTAMENTO, único para San Martín) y los identificadores (claves primarias y códigos). Las variables categóricas nominales (GENERO, ETNIA, PROVINCIA, RED, DESCRIPCION_FINANCIADOR) fueron convertidas en tensores numéricos binarios mediante One-Hot Encoding (`pd.get_dummies`), resultando en una matriz consolidada de 34 variables predictoras [4].

16.4. Prevención estricta de Data Leakage

La literatura científica resalta la fuga de datos como el mayor riesgo de invalidez en los modelos de Machine Learning. Para aislar completamente el experimento, el conjunto preparado se dividió de manera estratificada para mantener las proporciones de riesgo poblacional: 60% para entrenamiento (35,532 registros), 20% para validación de arquitectura (11,844 registros) y 20% para la prueba final ciega (11,845 registros) [4].

Para garantizar la integridad del experimento, la estandarización de las características continuas (StandardScaler) se calculó exclusivamente sobre la matriz de entrenamiento (fit_transform). Las medidas de escala resultantes fueron aplicadas a los conjuntos de validación y prueba únicamente mediante la función transform, emulando así un escenario real donde el sistema procesa datos nuevos sin incorporar su distribución en el conocimiento del modelo previo [4].

17. DISEÑO DE LA SOLUCIÓN

La solución analítica se diseñó bajo una arquitectura modular y secuencial, integrando el flujo de datos desde su captura cruda hasta la evaluación del algoritmo.




Figura 2: Arquitectura del Flujo de Datos

Componentes Tecnológicos:

- **Entradas:** Dataset administrativo gubernamental ANEMIA_DA.csv.
- **Procesos:** Pipeline de limpieza con pandas, partición de tensores con scikit-learn y generación visual con seaborn/matplotlib.

- **Salidas:** Modelos matemáticos entrenados, métricas de rendimiento y gráficos del EDA.
- **Tecnologías:** Entorno Cloud de ejecución interactiva (Google Colab), lenguaje Python (versión 3.x) y librerías especializadas en Machine Learning.

17.1. TÉCNICAS DE INGENIERÍA DE SOFTWARE APLICADAS A IA

Para asegurar la escalabilidad y reproducibilidad del proyecto, se aplicaron prácticas de Ingeniería de Software adaptadas al ciclo de vida del aprendizaje automático (MLOps) [1]:

Requisitos del Sistema:

- **Funcionales:** El sistema debe cargar los registros mediante conexión HTTP, limpiar las edades negativas y procesar las variables categóricas. Posteriormente, debe clasificar las instancias en riesgo severo y agrupar casos por latitud, longitud y edad.
- **No funcionales:** Alta disponibilidad de procesamiento (ejecución menor a 5 minutos en CPU estándar) y robustez algorítmica para evitar fugas de información.

Gestión del Código y Calidad:

- **Control de versiones:** El artefacto se gestiona bajo el paradigma de versionamiento de código estructurado, almacenando los notebooks analíticos, scripts y dependencias dentro de un repositorio de Git, garantizando el rastreo de cualquier cambio en las iteraciones de la investigación [1].
- **Estructura del Proyecto y README:** El repositorio cuenta con un archivo README.md obligatorio que detalla instrucciones claras sobre cómo clonar el entorno, instalar los requerimientos (requirements.txt) y reproducir el experimento con la misma semilla aleatoria (random_state=42), asegurando total transparencia metodológica [1].
- **Validación de Calidad:** En lugar del "testing de unidad" tradicional de software, la calidad en IA se aseguró mediante particiones rigurosas de datos (train/test split), estandarizando las características exclusivamente sobre el conjunto de entrenamiento para probar funcionalmente el modelo frente a los datos invisibles de prueba [1].

18. DESARROLLO DE LA IMPLEMENTACIÓN

18.1. DISEÑO DEL MODELO DE IA

Se seleccionaron dos algoritmos complementarios por su interpretabilidad clínica y ajuste a la topología de los datos [1]:

- Regresión Logística (Clasificación Supervisada): Se seleccionó este modelo porque la variable objetivo es binaria discreta y requiere probabilidad matemática interpretable. La estrategia de entrenamiento incorporó el hiperparámetro `class_weight="balanced"`, compensando así el desbalance poblacional natural de la anemia leve frente a la severa [3].
- K-Means (Agrupamiento No Supervisado): Se implementó para descubrir clústeres puramente geográfico-demográficos, excluyendo deliberadamente la etiqueta de severidad. Se entrenó utilizando la inercia (Distancia Euclidiana al cuadrado) para optimizar los centroides [3].

18.2. MODELO BASE (BASELINE)

Frente al riesgo del optimismo algorítmico excesivo, se estructuró un modelo Baseline mediante la clase `DummyClassifier` de Scikit-learn [3]. Este modelo ingenuo se configuró con la estrategia de predecir siempre la clase estadísticamente mayoritaria (Anemia Leve, que representaba el 78.4% de la muestra). Su implementación permitió fijar un límite inferior para demostrar empíricamente el valor matemático añadido por la Inteligencia Artificial propuesta [3].

19. DISEÑO DE EXPERIMENTACIÓN

Se diseñó un marco experimental controlado sobre el conjunto preprocesado, manteniendo la semilla generadora constante (`random_state=42`) para garantizar la reproducibilidad estricta.

Experimento	Modelo Algorítmico	Tipo de Aprendizaje	Variables de Entrada	Parámetros Clave	Métrica Principal
E1	Baseline (Dummy)	Ingenuo	34 Features	<code>most_frequent</code>	F1-Score
E2	Regresión Logística	Supervisado	34 Features	<code>class_weight="balanced"</code>	F1-Score / Recall
E3	K-Means	No Supervisado	Edad, Latitud, Longitud	$k \in \{2, 3, 4, 5, 6\}$ (Búsqueda)	Inercia
E4	K-Means Optimizado	No Supervisado	Edad, Latitud, Longitud	$k = 4$ (Óptimo)	Silhouette Score

Figura 3: Tabla de Experimentos Controlados

20. EVALUACIÓN

20.1. MÉTRICAS DE EVALUACIÓN

Para el modelo de clasificación (Regresión Logística), no se utilizó únicamente el Accuracy debido al fuerte desbalance de clases (78.4% de casos leves). Se priorizó el cálculo del F1-score y el Recall (Sensibilidad), dado que en salud pública es más crítico minimizar los falsos negativos (no detectar a un niño con riesgo severo). Para el modelo de agrupamiento (K-Means), se empleó la inercia (Método del Codo) para la selección de k, y el Silhouette Score para medir la cohesión y separación de los clústeres.

20.2. VALIDACIÓN

Se aplicó una división `train_test_split` estratificada (60% entrenamiento, 20% validación, 20% prueba). Se garantizó la ausencia de fuga de información ajustando la herramienta de escalado estándar (StandardScaler) estrictamente sobre la partición de entrenamiento, aplicando solo la transformación matemática a los conjuntos restantes.

20.3. COMPARACIÓN DE MODELOS

Los resultados empíricos sobre el conjunto de validación ciega (Test) demostraron la superioridad del clasificador frente al enfoque ingenuo:

Modelo Algorítmico	Accuracy	Precision	Recall	F1-Score
Baseline (Dummy)	784	0	0	0
Regresión Logística	554	270	625	377

Figura 4: Tabla de comparación de modelos

Aunque el Baseline presenta mayor Accuracy global, su F1-score es 0.0 porque jamás detecta un caso crítico. La Regresión Logística sacrifica exactitud general para lograr un Recall de 0.625 (detectando más del 60% de casos de riesgo real).

20.4. INTERPRETABILIDAD

La Regresión Logística seleccionada permite una alta interpretabilidad a través del peso de sus coeficientes, garantizando que los profesionales de salud puedan entender matemáticamente por qué el modelo clasifica un riesgo, evitando el problema de "caja negra" propio de las redes neuronales profundas.

20.5. EVALUACIÓN DEL ARTEFACTO Y PROTOTIPO

El prototipo funcional tecnológico es un Jupyter Notebook documentado. Se evaluó su robustez y escalabilidad computacional, logrando ejecutar el procesamiento completo de 59,225 registros, limpieza, entrenamiento y evaluación en tiempo real (segundos de cómputo en entorno Cloud).

20.6. DESPLIEGUE Y REPRODUCIBILIDAD

El artefacto se despliega en un repositorio de Git, garantizando su reproducibilidad al incluir una semilla de fijación de aleatoriedad (`random_state=42`) en todas las divisiones y algoritmos, permitiendo a cualquier investigador obtener la misma matriz de confusión.

21. RESULTADOS

Los resultados de la investigación se dividen en tres etapas empíricas: análisis exploratorio, clasificación predictiva y segmentación espacial.

21.1. Resultados del Análisis Exploratorio (EDA)

La exploración inicial confirmó el fuerte desbalance poblacional de la muestra, donde la gran mayoría de los casos diagnosticados corresponden a anemia leve, mientras que los casos de riesgo (moderada y severa) representan una fracción menor, lo cual justificó el balanceo de pesos en el algoritmo predictivo.




Figura 5: Distribución de casos por grado de severidad de anemia

El análisis de interacciones entre variables continuas demostró que no existe multicolinealidad severa entre las características de edad y geolocalización, garantizando la estabilidad de los coeficientes de la Regresión Logística.




Figura 6. Correlación entre variables numéricas

Asimismo, al cruzar la edad (en meses) con el nivel de severidad, se observó gráficamente la dispersión de los casos críticos, confirmando que la edad por sí sola no es un separador perfecto y requiere modelado multivariable.




Figura 7: Edad (en meses) según grado de severidad

21.2. Resultados de la Predicción de Riesgo (Regresión Logística)

Al evaluar el modelo supervisado sobre el conjunto de prueba (Test) aislado, el clasificador demostró su validez tecnológica. Mientras que el modelo Baseline arrojó un F1-Score nulo al ser incapaz de detectar los casos severos, la Regresión Logística logró capturar satisfactoriamente los verdaderos positivos de riesgo, alcanzando un Recall de 0.625.




Figura 8: Matriz de confusión — Modelo 1 (test)

Como se aprecia en la matriz de confusión, el modelo penaliza la exactitud global (generando falsos positivos) a cambio de maximizar la detección temprana de 1,595 pacientes reales con riesgo de severidad alta, cumpliendo el objetivo preventivo en salud pública.

21.3. Resultados de la Segmentación (K-Means)

Para la configuración del algoritmo no supervisado, la evaluación de la inercia (Distancia Euclidiana al cuadrado) mediante el método del codo determinó que el número óptimo de agrupaciones naturales en la región es $k=4$.




Figura 9: Método del codo para elegir k

Al ejecutar K-Means con este hiperparámetro, se obtuvo un coeficiente de Silhouette de 0.470. La visualización de las coordenadas reveló cuatro clústeres geográficos claramente diferenciados en el mapa espacial.




Figura 10: Clusters geográficos de casos de anemia ($k=4$)

La validación externa del modelo de agrupamiento cruzando los clústeres descubiertos con la etiqueta real de severidad que el

algoritmo no conocía demostró que el Clúster 2 concentra la mayor densidad de riesgo severo y moderado (24.6% acumulado), mientras que el Clúster 3 presenta un riesgo significativamente menor (13.6% acumulado). Esto demuestra que la segmentación IA descubre zonas de intervención prioritaria con alta efectividad empírica.

22. DISCUSIÓN

La experimentación cumplió la hipótesis operativa y los objetivos planteados: el sistema basado en aprendizaje automático funcionó. El modelo logró clasificar el riesgo y segmentar a los pacientes debido a que el riguroso proceso de ingeniería y preparación de datos (CRISP-DM) extrajo la señal subyacente necesaria, demostrando que algoritmos matemáticos pueden superar la capacidad predictiva de la estadística descriptiva tradicional en salud pública.

No obstante, al analizar dónde falló el modelo, se observa que la Regresión Logística sacrificó exactitud global (obteniendo un Accuracy de 0.554 frente al 0.784 del baseline) y generó una alta tasa de falsos positivos (baja precisión). Esta "falla" fue una decisión de diseño deliberada al aplicar el balanceo de clases, asumiendo que en el dominio médico es preferible investigar una falsa alarma que ignorar a un paciente verdaderamente crítico (maximizando el Recall). Las variables más determinantes para este comportamiento predictivo y de segmentación fueron la edad biológica estandarizada en meses y las coordenadas de ubicación espacial (latitud y longitud).

Al contrastar con la literatura científica, los hallazgos coinciden con Sabatini et al. [2] respecto a la viabilidad y utilidad del modelado lineal supervisado (Regresión Logística) para la clasificación de cuadros hematológicos con bajo costo computacional. Sin embargo, existen diferencias metodológicas clave: mientras investigaciones como la de Tian et al. [5] aplicaron clustering de forma puramente exploratoria, en este proyecto se logró superar esa limitación al realizar una validación externa, demostrando que los clústeres matemáticos tienen una correspondencia real con el diagnóstico clínico.

En el contexto real, los resultados de este artefacto tecnológico tienen un impacto directo en la toma de decisiones. El hecho de que el modelo de clustering identifique de forma no supervisada a un grupo específico (Clúster 2) con un 24.1% de incidencia severa, frente a zonas con apenas 13.3%, indica a

las autoridades sanitarias de la región San Martín exactamente en qué perfil geográfico-etario deben inyectar y priorizar el mayor presupuesto de suplementación preventiva, validando la utilidad práctica del sistema desarrollado.

23. AMENAZAS A LA VALIDEZ Y LIMITACIONES

Para garantizar el rigor científico del proyecto, se identifican las siguientes amenazas a la validez de los resultados:

- **Validez interna:** Aunque el experimento demuestra que la IA puede clasificar el riesgo, existe el problema de las variables omitidas. El modelo se basa en datos administrativos y geográficos, pero carece de variables clínicas profundas (ej. comorbilidades del niño, dieta exacta o nivel socioeconómico de los padres), lo que podría ser la verdadera causa subyacente de la severidad.
- **Validez externa:** El estudio se limita a los casos registrados en la región San Martín entre 2016 y 2025. En consecuencia, sus hallazgos no deben generalizarse automáticamente a otras regiones del Perú, ya que factores topográficos (como la altitud en los Andes) y demográficos alterarían el comportamiento del modelo.
- **Validez de constructo:** Al no existir en el dataset un grupo de comparación de niños sanos (sin anemia), los modelos desarrollados clasifican el riesgo relativo de severidad exclusivamente dentro de la población ya diagnosticada, no el riesgo de desarrollar la enfermedad en la población general. Además, la etiqueta predictiva es una derivación administrativa (GRADO_SEVERIDAD), no la medición exacta del nivel de hemoglobina en laboratorio.
- **Validez de conclusión:** La evidencia estadística se apoya en un tamaño de muestra robusto (59,225 registros originales). No obstante, la Accuracy del modelo de clasificación fue baja (0.554), lo que restringe las conclusiones: el modelo es válido únicamente como herramienta de tamizaje preventivo (por su alto Recall) y no como un sistema de diagnóstico médico concluyente.

Limitaciones técnicas y operativas adicionales:

- **Sesgo y calidad de los datos:** Se evidenció un fuerte sesgo de clase natural (78.4% de diagnósticos leves) y ruido en la calidad de los datos

gubernamentales (ingreso de edades negativas y errores tipográficos) que, aunque preprocesados, añaden incertidumbre al registro real.

- **Restricciones temporales:** El conjunto de datos tiene como fecha de corte abril de 2025, por lo que el modelo no captura cambios en políticas de salud implementadas después de esa fecha.
- **Limitaciones del modelo y restricciones computacionales:** El algoritmo K-Means es inherentemente sensible a valores atípicos espaciales (outliers). Además, el desarrollo se ejecutó bajo restricciones computacionales en un entorno de ejecución estándar (Google Colab), lo que impidió la implementación de redes neuronales profundas o búsquedas hiperparamétricas masivas (Grid Search exhaustivo).

24. CONSIDERACIONES ÉTICAS

El desarrollo de este sistema predictivo se rigió por estrictos estándares éticos, dado el manejo de información sensible de salud pública infantil:

- **Privacidad, anonimización y datos personales:** Se garantizó la privacidad absoluta del paciente al utilizar un registro gubernamental (ANEMIA_DA) donde la información personal está completamente anonimizada desde su origen (sin nombres, direcciones exactas ni documentos de identidad) [4]. Al tratarse de la Plataforma Nacional de Datos Abiertos, se respetan las normas peruanas de protección de datos personales, asumiendo el consentimiento implícito de la data agregada para fines de investigación epidemiológica pública.
- **Sesgo algorítmico y discriminación:** Se mitigó activamente el sesgo algorítmico mediante el balanceo de clases durante el entrenamiento del modelo. El objetivo ético fue evitar cualquier tipo de discriminación computacional que pudiera desfavorecer o invisibilizar el riesgo en poblaciones vulnerables de zonas rurales.
- **Explicabilidad:** Se priorizó el uso de un modelo lineal (Regresión Logística) sobre algoritmos de "caja negra" complejos para garantizar una alta explicabilidad, permitiendo a los médicos auditar claramente qué factores (coeficientes) determinaron la predicción de riesgo severo.
- **Seguridad y uso responsable de IA:** El sistema fue concebido bajo el principio de IA responsable: actúa exclusivamente como una herramienta analítica de soporte para la priorización de recursos, y en ningún escenario busca automatizar o reemplazar el diagnóstico ni el criterio

clínico humano. Asimismo, se mantuvo la seguridad de la información limitando la ejecución al entorno de desarrollo sin exponer datos en servidores públicos inseguros.

- **Propiedad intelectual:** Se respeta la propiedad intelectual reconociendo formalmente al Ministerio de Salud (MINSA) como propietario de los datos originales, liberando el código fuente y el prototipo desarrollado bajo fines estrictamente académicos.

25. REPRODUCIBILIDAD

Para garantizar la reproducibilidad empírica de esta investigación y permitir su auditoría técnica, el sistema tecnológico ha sido empaquetado siguiendo las mejores prácticas de la ingeniería de software aplicada a datos [1]. El código fuente completo, desarrollado en un entorno interactivo de Google Colab (Python 3), se entrega estructurado junto con el acceso directo al conjunto de datos original (ANEMIA_DA.csv).

Asimismo, se incluye un archivo de documentación técnica (README.md) que detalla las instrucciones de instalación, dependencias y ejecución del proyecto [1]. Para asegurar que la experimentación no sufra variaciones estocásticas en futuras ejecuciones, todas las particiones de datos (train_test_split) y la inicialización de los algoritmos (tanto Regresión Logística como K-Means) fueron ancladas a una semilla aleatoria fija (random_state=42) [1]. Esta configuración estricta asegura que cualquier investigador externo que compile el código obtendrá exactamente las mismas métricas de rendimiento, agrupaciones geográficas y matrices de confusión que han sido presentadas y discutidas en este informe.

26. CONCLUSIONES

- **Respecto al OE1**, el análisis exploratorio de datos (EDA) evidenció un marcado desbalance poblacional (78.4% de diagnósticos leves) y demostró gráficamente la ausencia de multicolinealidad severa entre las características numéricas, lo cual justificó la posterior configuración algorítmica de pesos balanceados.
- **Respecto al OE2**, el proceso de ingeniería y preprocesamiento permitió consolidar un conjunto de datos robusto de 34 variables predictoras, logrando estandarizar biológicamente las unidades de edad a meses y

transformando exitosamente las variables categóricas nominales mediante One-Hot Encoding.

- **Respecto al OE3**, el esquema de partición estratificada (60% entrenamiento, 20% validación, 20% prueba) y la aplicación del escalado (StandardScaler) exclusivamente sobre la partición de entrenamiento garantizaron una evaluación predictiva imparcial y previnieron de manera estricta la fuga de información computacional (*data leakage*).
- **Respecto al OE4 y OE5**, se implementó y validó una Regresión Logística que demostró eficacia técnica al predecir el riesgo de anemia severa. Este modelo logró un Recall de 0.625 sobre datos nunca antes vistos, superando absolutamente el F1-Score nulo (0.000) obtenido por el modelo ingenuo base (*Baseline*).
- **Respecto al OE6**, el modelo no supervisado K-Means (optimizado con $k = 4$ clústeres según el método del codo) logró segmentar a la población pediátrica con un Silhouette score de 0.470. Estos clústeres descubiertos probaron tener una alta heterogeneidad clínica al validarse externamente, identificando zonas con variaciones de riesgo severo que oscilan entre el 13.3% y el 24.1%.

27. RECOMENDACIONES

Derivado de los resultados y las limitaciones identificadas en la investigación, se plantean las siguientes recomendaciones accionables:

- ❖ **A nivel de calidad de datos:** Dado que la validez del modelo está limitada por la falta de variables clínicas profundas, se recomienda a las entidades de salud del MINSA estandarizar la recolección de datos adicionales (como niveles exactos de hemoglobina en sangre, dieta y comorbilidades) en los futuros registros de la plataforma de Datos Abiertos.
- ❖ **A nivel tecnológico:** Se recomienda a nivel institucional el empaquetado de estos algoritmos validados en una API REST (utilizando frameworks ligeros como FastAPI o Flask) para que los establecimientos de salud puedan integrarlo a sus sistemas y consultar el riesgo de nuevos pacientes en tiempo real.

27.1. TRABAJO FUTURO

Para dar continuidad a esta línea de investigación tecnológica, se proponen las siguientes extensiones:

- **Nuevos datos y dominios:** Escalar el entrenamiento del modelo incorporando datasets de regiones con mayor altitud geográfica (ej. Puno o Cusco) para analizar cómo el factor de la altitud modifica los coeficientes de predicción de anemia.
- **Nuevos algoritmos:** Explorar la implementación de algoritmos de ensamblaje más complejos (como Random Forest o XGBoost) para comparar si el aumento en la complejidad del modelo mejora el Accuracy sin sacrificar la explicabilidad lograda.
- **Aprendizaje continuo:** Desarrollar un pipeline de aprendizaje continuo (Continuous Training) que permita al modelo reentrenarse automáticamente conforme el MINSA actualice los registros de ANEMIA_DA en los próximos años académicos.

28. REFERENCIAS

- [1] Instituto Nacional de Estadística e Informática (INEI), "El 34,9% de la población de 6 a 35 meses de edad sufrió de anemia en el 2025", Nota de Prensa, Plataforma del Estado Peruano, may. 2026. [En línea]. Disponible en: <https://www.gob.pe/institucion/inei/noticias>.
- [2] G. Sabatini et al., "Anemia Classification System Using Machine Learning", MDPI, vol. 12, no. 1, p. 19, feb. 2025.
- [3] Organización Mundial de la Salud, Concentraciones de hemoglobina para diagnosticar la anemia y evaluar su gravedad, Ginebra: OMS, 2011.
- [4] Ministerio de Salud (MINSA), "Plataforma Nacional de Datos Abiertos: Casos de Anemia (ANEMIA_DA)", Gobierno del Perú, 2025.
- [5] X. Tian et al., "Analysis of anemia disease in Pakistan using logistic regression", ResearchGate, jul. 2026.
- [6] Fondo de las Naciones Unidas para la Infancia (UNICEF), "Que la anemia no los alcance: La anemia es una amenaza para el Desarrollo Infantil Temprano", Perú, 2024. [En línea]. Disponible en: <https://www.unicef.org/peru/que-la-anemia-no-los-alcance>.
- [7] T. Mitchell, Machine Learning, 1ra ed. Nueva York, NY, EE. UU.: McGraw-Hill, 1997.
- [8] C. M. Bishop, Pattern Recognition and Machine Learning, Nueva York, NY, EE. UU.: Springer, 2006.
- [9] I. Goodfellow, Y. Bengio, y A. Courville, Deep Learning, Cambridge, MA, EE. UU.: MIT Press, 2016.

29. ANEXOS

- ❖ **Anexo A: Descripción completa del dataset** A continuación, se detalla la estructura computacional del registro `ANEMIA_DA.csv` tras su carga inicial, evidenciando las 59,225 filas y 22 columnas originales.

```
1 # Comprensión de los datos
2 print("Columnas:", df.columns.tolist())
3 print()
4 df.info()
5 print()
6 print("Valores nulos por columna:")
7 print(df.isna().sum())
```

```
*** Columnas: ['PK_REGISTRO', 'FECHA_REGISTRO', 'GENERO', 'EDAD_REGISTRO', 'TIPO_EDAD', 'ETNIA', 'F_ATENCION', 'GRADO_SEVERIDAD', 'DIAGNOSTICO',
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 59225 entries, 0 to 59224
Data columns (total 22 columns):
#   Column              Non-Null Count  Dtype
---  -
0   PK_REGISTRO         59225 non-null  int64
1   FECHA_REGISTRO      59225 non-null  int64
2   GENERO              59225 non-null  object
3   EDAD_REGISTRO       59225 non-null  int64
4   TIPO_EDAD           59225 non-null  object
5   ETNIA               59225 non-null  object
6   F_ATENCION          59225 non-null  int64
7   GRADO_SEVERIDAD     59225 non-null  object
8   DIAGNOSTICO         59225 non-null  object
9   TIPO_DIAGNOSTICO    59225 non-null  object
10  DESCRIPCION_FINANCIADOR 59225 non-null  object
11  CANTIDAD             59225 non-null  int64
12  PROVINCIA           59225 non-null  object
13  DEPARTAMENTO         59225 non-null  object
14  DISTRITO            59225 non-null  object
15  RED                 59225 non-null  object
16  MICRORRED           59225 non-null  object
17  NOMBRE_ESTABLECIMIENTO 59225 non-null  object
18  CODIGO_UNICO        59225 non-null  int64
19  LONGITUD            59225 non-null  float64
20  LATITUD             59225 non-null  float64
21  FECHA_CORTE         59225 non-null  int64
dtypes: float64(2), int64(7), object(13)
memory usage: 9.9+ MB
```

- ❖ **Anexo B: Código fuente y Repositorio**

El código fuente completo en Python, estructurado bajo la metodología CRISP-DM, se adjunta a la presente entrega en el archivo ejecutable “PachecoAnton_Fatima_Parcial_Seccion_A.ipynb”. Su ejecución requiere un entorno con las librerías pandas, numpy, scikit-learn, matplotlib y seaborn.

- ❖ **Anexo D: Resultados completos**

A continuación, se presenta el volcado de la consola (log de ejecución) con las métricas detalladas de evaluación obtenidas

durante la validación del clasificador de Regresión Logística.

```
1 from sklearn.metrics import (
2     accuracy_score, precision_score, recall_score, f1_score, confusion_matrix
3 )
4
5 def evaluar_clasificacion(model, Xs, y_true, nombre):
6     pred = model.predict(Xs)
7     acc = accuracy_score(y_true, pred)
8     prec = precision_score(y_true, pred, zero_division=0)
9     rec = recall_score(y_true, pred, zero_division=0)
10    f1 = f1_score(y_true, pred, zero_division=0)
11    cm = confusion_matrix(y_true, pred)
12    print(f"--- {nombre} ---")
13    print(f"Accuracy : {acc:.3f}")
14    print(f"Precision: {prec:.3f}")
15    print(f"Recall   : {rec:.3f}")
16    print(f"F1-score : {f1:.3f}")
17    print("Matriz de confusión:\n", cm)
18    print()
19    return acc, prec, rec, f1, cm
20
21 print("=== Validación ===")
22 evaluar_clasificacion(baseline, X_val_s, y_val, "Baseline")
23 evaluar_clasificacion(modelo1, X_val_s, y_val, "Modelo 1: Regresión Logística")

```

```
*** === Validación ===
--- Baseline ---
Accuracy : 0.784
Precision: 0.000
Recall   : 0.000
F1-score : 0.000
Matriz de confusión:
[[9290  0]
 [2554  0]]

--- Modelo 1: Regresión Logística ---
Accuracy : 0.567
Precision: 0.279
Recall   : 0.633
F1-score : 0.387
Matriz de confusión:
[[5101 4189]
 [ 937 1617]]


```

❖ Anexo E: Configuración de experimentos

Para garantizar la reproducibilidad estricta, los hiperparámetros fijados en el código fueron:

- + Semilla de aleatoriedad (Random State): 42 (aplicado en particiones y modelos).
- + Partición de datos: test_size=0.4 (luego dividido en 0.5 para validación/test) y stratify=y.
- + Regresión Logística: max_iter=1000, class_weight="balanced".
- + K-Means: n_clusters=4, n_init=10.

30. README



31. MATRIZ DE TRAZABILIDAD FINAL

Objetivo	Actividad	Artefacto	Evidencia	Resultado	Sección del paper
OE1	Análisis exploratorio de datos (EDA)	Código Colab (EDA)	Gráficos (Heatmap, boxplots)	Distribución y correlaciones identificadas	16 y 21
OE2	Preprocesamiento y limpieza	Dataset preparado	Código de limpieza ejecutado	Datos estandarizados y codificados	15 y 16
OE3	Partición estratificada	Matrices Train/Val/Test	Dimensiones impresas en consola	Prevención estricta de Data Leakage	16 y 20
OE4	Desarrollo e implementación IA	Algoritmos en Python	Código de entrenamiento	Modelos matemáticos entrenados	18
OE5	Experimentos y evaluación (Logística)	Tabla comparativa	F1-Score, Recall, Matriz de Confusión	Modelo clasificador supera al baseline	20 y 21
OE6	Validación de segmentación (K-Means)	Mapa de clústeres	Silhouette Score, Gráfico del Codo	Perfiles de riesgo segmentados y validados	20 y 21